

DM_第三組

成人人口普查收入

指導教授：鮑永誠 老師

組長：111029208吳文秀

組員：112029043朱芯優

112029012翁鈺淇

111029030魏麒恩

111029040劉涵雲

目錄

壹、資料描述.....	
貳、資料前處理.....	
參、資料視覺化.....	
肆、問題假說.....	
伍、模型建立.....	
一、隨機森林.....	
二、決策樹.....	
三、羅吉斯迴歸.....	
陸、教授提問與問題回覆、解決策略.....	
柒、附錄.....	
一、工作分配表.....	
二、討論過程與組員照片.....	
捌、心得感想.....	
玖、參考資料.....	

壹、資料描述

(一)資料介紹

本資料來源由 RONNY KOHAVI 和 BARRY BECKER(數據挖掘和可視化, SILICON GRAPHICS)從1994年人口普查局數據庫中提取。統計目的是為了研究一個人年收入是否超過五萬美元, 欄位包含年齡、性別、工作單位、教育程度、職業、種族、工作時數、收入等等, 共有32,561筆資料, 16個資料欄位。

(二)探究動機

我們選擇這個主題, 是因為「收入」可能與「教育、性別、年齡」等因素密切相關, 這些因素其實都反映了社會階層與資源分配的問題。透過成人人口普查資料, 也許可以幫助政策制定者了解不同族群在經濟上的落差, 進一步作為制定社會政策與教育政策的重要參考依據。

(三)原始資料說明

1. 連續型資料

<u>欄位名稱</u>	<u>說明</u>	<u>範例值</u>
<u>age</u>	<u>年齡(以歲為單位)</u>	<u>17-90</u>
<u>fnlwgt</u>	<u>最終權重,</u> <u>代表該筆樣本在母體</u> <u>中的代表性</u>	<u>12285-1,484,705</u>
<u>education.num</u>	<u>教育程度數值化</u> <u>(年級數)</u>	<u>1-16</u>

<u>capital.gain</u>	資本收益	<u>0-99,999</u>
<u>capital.loss</u>	資本損失	<u>0-4,356</u>
<u>hours.per.week</u>	每週工作時數	<u>1-99</u>

2. 類別型資料

<u>欄位名稱</u>	<u>說明</u>	<u>範例值</u>
<u>workclass</u>	<u>工作類別(如政府、私人企業、自營等)</u>	<u>Private, Self-emp-not-inc</u>
<u>education</u>	<u>教育程度名稱</u>	<u>HS-grad, Bachelors</u>
<u>marital.status</u>	<u>婚姻狀況</u>	<u>Married-civ-spouse, Divorced, Widowed, Separated, Never-married</u>
<u>occupation</u>	<u>職業類別</u>	<u>Prof-specialty, Sales</u>
<u>relationship</u>	<u>家庭關係</u>	<u>Husband, Not-in-family</u>
<u>race</u>	<u>種族</u>	<u>White, Black, Asian-Pac-Islander</u>
<u>sex</u>	<u>性別</u>	<u>Male, Female</u>
<u>native.country</u>	<u>原生國家</u>	<u>United-States, Mexico</u>
<u>income</u>	<u>收入分類(是否超過 50,000 美元)</u>	<u><=50K, >50K</u>

貳、資料前處理

(一)刪除無需使用之欄位

我們利用SPSS軟體，將native.contry進行次數統計，發現在整份資料中「United-States」的比例極高，佔約91%，因此認為對我們想分析的問題並無太多幫助，故決議將此欄位刪除。

(二)將資料編碼成有意義的單位

我們在初次執行後續模型時，因準確度極低，故在課堂小組討論期間向老師提問，老師建議我們可以把資料定義得更清楚，否則跑出來的結果意義不大且難以解釋。

1. age_cat

- a. 18~25歲設成1，為青少年
- b. 26~35歲設成2，為青壯年
- c. 36~65歲設成3，為壯年

2. wor_cat

- a. "0"為無薪或其他工作
- b. "1"為私人或自營企業
- c. "2"為政府相關企業

3. edun_cat

- a. "1"為0-5級 表示"教育程度低"
- b. "2"為6-10級 表示"教育程度中"
- c. "3"為11-15級 表示"教育程度中高"
- d. "4"為16-20級 表示"教育程度高"

4. mar_cat

- a. "0"表示未婚或非伴侶
- b. "1"表示已婚
- c. "2"表示其他(喪偶)

5. occ_cat

- a. "0"為低技能
- b. "1"為技術中等
- c. "2"為高技能

6. rel_cat

- a. "0"為無家庭關係
- b. "1"為旁系
- c. "2"為直系

7. sex_cat

- a. 男性設為1
- b. 女性設為2

8. income_bin

- a. $\leq 50k$ 美元設成 0, 為低收入
- b. $> 50k$ 美元設成 1, 為高收入

*income 在原始資料中就只有「 $\leq 50k$ 」、「 $> 50k$ 」兩種分

9. sex_cat

- a. "0" 為發展落後地區
- b. "1" 為新興經濟體
- c. "2" 為已開發國家

10. race_cat

- a. "1" 為白人
- b. "2" 為黑人
- c. "3" 為亞裔美國人
- d. "4" 為愛斯基摩人
- e. "5" 為其他

11. edu_cat

- a. "0" 為低學歷(國小以下)
- b. "1" 為中學歷(國高中)
- c. "2" 為高學歷(大學以上)

(三) google colab 檢查

將資料整理後, 使用 google colab 檢查可以得知各項資料有無遺漏值, 以及遺漏值總共有多少。



(四) 刪除遺漏值

我們使用Excel將資料全部選取後點選資料點擊篩選問號找出遺漏值，並將其刪除。如(三)的檢查表所示，有遺漏值的數據有workclass、occupation、native.country，我們將有遺漏值的欄位通通以相同方式處理乾淨。

(五)資料平衡

1. 整理完資料後，由於我們主要想分析「收入與其他特徵的關係(什麼特徵影響收入最重大)」，我們發現在原始資料中我們的資料是不平衡且差距極大的，因此小組決定針對低收做下採樣而針對高收做SMOTE上採樣的方式來讓資料平衡。
如附圖所示:平衡後income=0以及income=1皆為11540筆。

2. 將資料平衡至一樣的數目後，我們需要處理剩下的負樣本。

3. 以下為整理好的資料，資料筆數由原本的32561筆➡28852筆。

參、資料視覺化

(一)熱力圖

熱力圖程式碼截圖

```
#step 1.上傳.sav檔案
from google.colab import files
upload = files.upload()

#step 2. 0 安裝 pyreadstat(讀 .sav 必備)
!pip install pyreadstat

import pyreadstat
import pandas as pd

# step 3.讀取 .sav 檔案
#upload.keys()會抓到你剛上傳檔名
import pyreadstat

df, meta = pyreadstat.read_sav(file_name)

print("資料筆數與欄位形狀:", df.shape)
df.head()
```

我們使用Python來繪製熱力圖，並以完成前處理後之資料作為分析基礎。透過熱力圖可視覺化各特徵之間的相關係數關係。由於本組資料已統一轉換為類別型資料，各變數間的數值差異相對不大。由圖中結果可觀察到，收入(income)與教育程度(education.num)之相關係數為 0.7 ，而與每週工作時數(hours.per.week)之相關係數為 0.7 。此結果顯示收入可能與教育程度及工作時數存在一定程度的關聯性，進而促使我們進一步探討教育年數與收入

```

#step 4. 抓出所有數值欄位(才能算相關係數)
numeric_cols = df.select_dtypes(include=["float64", "int64"]).columns

print("可用於相關係數的欄位:")
print(numeric_cols)


#step 5. 計算相關矩陣
corr = df[numeric_cols].corr()
corr

#step 6. 畫熱力圖
import seaborn as sns
import matplotlib.pyplot as plt

plt.figure(figsize=(12,10))
sns.heatmap(corr, annot=True, cmap='coolwarm', fmt=".2f")
plt.title("Correlation Heatmap (Numerical Variable Improvement Analysis)")
plt.show()


```

之間是否具有顯著影響關係。




(二)其他視覺化圖表

1.教育程度與性別收入



2.不同工作時長下的職業收入狀況



肆、問題假說

如前述分析所示，我們對資料集中之「income」變數特別關注。本研究以成人人口普查資料為基礎，建構高收入預測模型，並進一步分析影響高收入的關鍵人口與社經特徵。。

Q1:成人人口普查資料中，哪些人口與社經特徵能有效預測個體是否屬於高收入族群？


伍、模型建立

(一)隨機森林

1. 模型介紹:隨機森林是一種以多顆決策樹為基礎的集成式學習方法，透過 Bootstrap 隨機抽樣的方式自原始資料集中抽取子樣本，以確保模型訓練過程具

備隨機性。Bootstrap 的取樣方式具有均勻且可重複抽樣的特性，使每棵決策樹所使用的資料略有差異。

隨機森林模型由多棵決策樹共同組成，最終結果由各決策樹進行整體判斷，有助於降低模型過度擬合的風險。過度擬合是指模型在訓練資料上表現良好，但在測試資料上的誤差明顯增加，常見原因包含資料量不足或過度追求訓練準確率。與我們所做的另外兩個模型相較之下，隨機森林能透過多模型整合的方式，使預測結果較為穩定。



2. 模型程式碼:

```
# =====
# 0. 安裝套件 (Colab 才需要)
# =====
!pip install pyreadstat seaborn
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import StratifiedKFold, cross_val_score
from sklearn.metrics import accuracy_score

# =====
# 1. 讀入套件
# =====
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import (
    confusion_matrix,
    accuracy_score,
    classification_report,
    roc_curve,
    auc
)

# =====
# 2. 載入訓練 / 測試資料
# =====
train_path = "/content/train_data.csv"
test_path = "/content/test_data.csv"

try:
    train_data = pd.read_csv(train_path)
    test_data = pd.read_csv(test_path)
    print("訓練與測試資料載入成功!")
except Exception as e:
    print(f"讀取失敗: {e}")
    exit()

# =====
# 3. 指定目標欄位
# =====
TARGET_COLUMN = "income_bin"  # ←請確認這個名稱

if TARGET_COLUMN not in train_data.columns:
    print("找不到目標欄位，請確認名稱")
    print(train_data.columns.tolist())
    exit()

# =====
# 4. 切分 X / y (已分好，不再 split)
# =====
X_train = train_data.drop(TARGET_COLUMN, axis=1)
y_train = train_data[TARGET_COLUMN]

X_test = test_data.drop(TARGET_COLUMN, axis=1)
y_test = test_data[TARGET_COLUMN]

# =====
# 5. 目標變數編碼
# =====
le = LabelEncoder()
y_train = le.fit_transform(y_train)
y_test = le.transform(y_test)

# =====
# 6. 缺失值處理 (數值)
# =====
for col in X_train.columns:
    if X_train[col].dtype in [np.float64, np.int64]:
        median_val = X_train[col].median()
        X_train[col] = X_train[col].fillna(median_val)
        X_test[col] = X_test[col].fillna(median_val)

# =====
# 7. 類別變數 One-hot 編碼
# =====
cat_cols = X_train.select_dtypes(include=['object', 'category']).columns

X_train = pd.get_dummies(X_train, columns=cat_cols, drop_first=True)
X_test = pd.get_dummies(X_test, columns=cat_cols, drop_first=True)

# 封套欄位
X_train, X_test = X_train.align(X_test, join='left', axis=1, fill_value=0)

print("資料前處理完成")

# =====
# 8. 訓練 Random Forest (保守設定)
# =====
model = RandomForestClassifier(
    n_estimators=100,
    max_depth=1,
    min_samples_leaf=20,
    random_state=42,
    n_jobs=-1
)

print("開始訓練模型...")
model.fit(X_train, y_train)
```

```
# =====
# 9. 五折交叉驗證
# =====from imblearn.over_sampling import SMOTE
smote = SMOTE(random_state=42)
X_train_res, y_train_res = smote.fit_resample(X_train, y_train)

from sklearn.model_selection import StratifiedKFold, cross_val_score
from sklearn.metrics import accuracy_score, classification_report
import numpy as np
import pandas as pd

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

# 五折交叉驗證 accuracy
cv_scores = cross_val_score(
    model,
    X_train_res,
    y_train_res,
    cv=cv,
    scoring='accuracy'
)

print("五折交叉驗證準確率:", cv_scores)
print("平均準確率:", cv_scores.mean())

report_accum = []

for train_idx, val_idx in cv.split(X_train_res, y_train_res):
    X_tr = X_train_res.iloc[train_idx]
    X_val = X_train_res.iloc[val_idx]
    y_tr = y_train_res[train_idx]
    y_val = y_train_res[val_idx]

    model.fit(X_tr, y_tr)
    y_val_pred = model.predict(X_val)

    report_accum.append(
        classification_report(y_val, y_val_pred, output_dict=True)
    )

# 平均 precision / recall / f1
avg_report = {}

for key in report_accum[0].keys():
    if key == 'accuracy':
        continue
    avg_report[key] = {}
    for metric in report_accum[0][key]:
        avg_report[key][metric] = np.mean(
            [r[key][metric] for r in report_accum]
        )

print("\n五折交叉驗證平均分類報告:")
print(pd.DataFrame(avg_report).T)

model.fit(X_train_res, y_train_res)

y_train_pred = model.predict(X_train_res)
y_test_pred = model.predict(X_test)

print("\n訓練集準確率:", accuracy_score(y_train_res, y_train_pred))
print("測試集準確率:", accuracy_score(y_test, y_test_pred))
```

```
# =====
# 10. 混淆矩陣對比
# =====
fig, axes = plt.subplots(1, 2, figsize=(16, 6))

# Train
cm_train = confusion_matrix(y_train, y_train_pred)
acc_train = accuracy_score(y_train, y_train_pred)
sns.heatmap(cm_train, annot=True, fmt='d', cmap='Oranges', ax=axes[0])
axes[0].set_title(f'Train Confusion Matrix\nAccuracy={acc_train:.4f}')

# Test
cm_test = confusion_matrix(y_test, y_test_pred)
acc_test = accuracy_score(y_test, y_test_pred)
sns.heatmap(cm_test, annot=True, fmt='d', cmap='Blues', ax=axes[1])
axes[1].set_title(f'Test Confusion Matrix\nAccuracy={acc_test:.4f}')

plt.tight_layout()
plt.show()

# =====
# 11. ROC Curve 對比
# =====
fpr_tr, tpr_tr, _ = roc_curve(y_train, y_train_prob)
fpr_te, tpr_te, _ = roc_curve(y_test, y_test_prob)

auc_tr = auc(fpr_tr, tpr_tr)
auc_te = auc(fpr_te, tpr_te)

plt.figure(figsize=(8, 6))
plt.plot(fpr_tr, tpr_tr, label=f'Train AUC={auc_tr:.4f}')
plt.plot(fpr_te, tpr_te, linestyle='--', label=f'Test AUC={auc_te:.4f}')
plt.plot([0, 1], [0, 1], linestyle=':', label='Random Guess')

plt.xlabel('FPR')
plt.ylabel('TPR')
plt.title('ROC Curve Comparison')
plt.legend()
plt.grid()
plt.show()

# =====
# 12. 成效報告
# =====
print(f"Train Accuracy: {acc_train:.4f}")
print(f"Test Accuracy: {acc_test:.4f}")

print("\n--- Train Classification Report ---")
print(classification_report(y_train, y_train_pred))

print("\n--- Test Classification Report ---")
print(classification_report(y_test, y_test_pred))
```

3. 隨機森林超參數:

樹的數量	100
樹深	4
抽資料方式	80/20法則
樹葉節點	20
亂數種子	42


其他參數皆為預設值。

4. 隨機森林其他資料:抽樣時將資料進行下採樣後再來進行隨機抽樣，使訓練集的income達成類別平衡，income有兩種類別，分為0、1各抽**17340**、**17341**筆 測試集的income中0、1個別抽**4336**、**4335**筆。
5. 利用混淆矩陣檢驗模型:


準確率(Accuracy)		(TP+TN) / (TP+TN+FP+FN)
精確率	$Precision = \frac{TP}{TP + FP}$	判斷為真的情況下，有多少真是真的正例
召回率	$Recall = \frac{TP}{TP + FN}$	事實為真的樣本中有幾個是預測正確的
F1分數	$F1-score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$	同時考慮精確率和召回值是兩者間的調和平均

	預測為真	預測為假
實際為真	真陽性 (TP)	偽陰性 (FN)
實際為假	偽陽性 (FP)	真陰性 (TN)

5.1訓練集的混淆矩陣



5.2測試集的混淆矩陣



6. 隨機森林結果

6.1.模型準確度

訓練集約為**0.7899**，測試集約為**0.7536**，此結果**100**棵樹集體投票後的準確度每個預測都是由所有**100**棵樹共同決定的

```
Train Accuracy: 0.7899
Test  Accuracy: 0.7536
```

6.2.五折交叉驗證結果

平均準確率為**0.7873**

五折交叉驗證準確率: [0.78596187 0.78704506 0.78531196 0.78336222 0.7952773]
平均準確率: 0.7873916811091854

五折交叉驗證平均分類報告:

	precision	recall	f1-score	support
0	0.833487	0.719151	0.771688	2308.0
1	0.753206	0.855633	0.800928	2308.0
macro avg	0.793347	0.787392	0.786308	4616.0
weighted avg	0.793347	0.787392	0.786308	4616.0

(二)決策樹

決策樹是一種以樹狀結構進行分類與預測的模型，透過逐層判斷特徵條件，將資料分割成不同群組，最終得到預測結果。其結構主要可分為以下幾個部分：

1. 模型介紹:

- 根節點: 表示所有數據的起始點
- 內部節點: 根據某一特徵作為判斷條件，將資料進行分割
- 分支: 依據內部節點的判斷結果所產生的資料分流方向
- 葉節點: 終極預測結果的節點，通常對應最終的類別

2. 決策樹的優與缺:

- 優點:
 - 模型結構直觀，容易理解與解釋
 - 對缺失值較不敏感
 - 可處理數值型與類別型的資料

b. 缺點:

- i. 容易因過度學習訓練資料而產生過度擬合
- ii. 在類別分布不平衡的資料集中, 模型表現可能較不理想
- iii. 當資料量龐大時, 模型訓練時間可能較長

3. 資訊量評估的方法:

- a. 熵(Entropy): 作為衡量資料不確定性或混亂程度的指標。熵值越高, 表示資料分布越混亂, 模型進行分類的難度也越高; 反之, 熵值越低, 代表資料越集中, 模型越容易進行判斷與預測。


$$\text{Entropy}(S) = - \sum_{i=1}^m p_i \log_2 p_i$$

- b. gini係數: gini係數用於衡量資料中各類別的純度, 常作為決策樹進行節點分割時的評估指標。gini係數值越低, 代表該節點中的資料越集中於單一類別, 純度越高。因此, 在建立決策樹時, 模型會選擇使gini不純度最小的特徵作為分割依據, 以提升分類效果。


$$\text{Gini Impurity}(S) = 1 - \sum_{i=1}^k p_i^2$$

4. 混淆矩陣:

- a. 訓練集:



b. 測試集:



c. 程式碼照片


```

# =====
# 10 混淆矩陣圖
# =====
def plot_confusion(y_true, y_pred, title):
    cm = confusion_matrix(y_true, y_pred)
    plt.figure(figsize=(6,4))
    sns.heatmap(cm, annot=True, fmt="d", cmap="Blues",
                xticklabels=["Low Income", "High Income"],
                yticklabels=["Low Income", "High Income"])


    plt.xlabel("Predicted")
    plt.ylabel("Actual")
    plt.title(title)
    plt.show()

plot_confusion(y_train_res, y_train_pred, "Confusion Matrix - Train Set")
plot_confusion(y_test, y_test_pred, "Confusion Matrix - Test Set")


```

5. ROC曲線:

a. 訓練集:



b. 測試集:



c. 程式碼照片:

```
# =====
# 1 ROC 曲線
# =====
def plot_roc(X, y_true, title):
    y_prob = model.predict_proba(X)[:,1]
    fpr, tpr, _ = roc_curve(y_true, y_prob)
    roc_auc = auc(fpr, tpr)
    plt.figure(figsize=(6,6))
    plt.plot(fpr, tpr, color='darkorange', lw=2, label='ROC curve (AUC = %.2f)' % roc_auc)
    plt.plot([0,1],[0,1], color='navy', lw=2, linestyle='--')
    plt.xlim([0.0,1.0])
    plt.ylim([0.0,1.0])
    plt.xlabel('False Positive Rate')
    plt.ylabel('True Positive Rate')
    plt.title(title)
    plt.legend(loc="lower right")
    plt.show()


plot_roc(X_train_res, y_train_res, "ROC Curve - Train Set")
plot_roc(X_test, y_test, "ROC Curve - Test Set")
```

6. 特徵重要性:

- 由於我們主要關注各項特徵對「income」變數的重要程度，因此在建立決策樹模型之前，先進行特徵重要性 (Feature Importance) 分析，以了解不同特徵對收入預測的影響程度，並作為後續決策樹建模的參考。
- 根據分析結果可知，「婚姻狀態」與「教育程度」對「income」皆具有顯著影響，其中以「婚姻狀態」的重要程度最高。因此，在決策樹建

構過程中，模型會優先選擇「婚姻狀態」作為根節點，並依此進一步進行資料分割與分類。

C.



d. 程式碼附圖

```
# =====  
# 1 2 特徵重要性圖  
# =====  
importances = pd.Series(model.feature_importances_, index=X_train_res.columns).sort_values(ascending=False)  
print("\n特徵重要性: \n", importances.head(20))  
  
plt.figure(figsize=(10,6))  
sns.barplot(x=importances.values[:20], y=importances.index[:20], palette="viridis")  
plt.title("Top 20 Feature Importance")  
plt.show()
```

7. 交叉驗證與模型準確度:

a. 模型準確度:訓練集約為**0.80**, 測試集約為**0.76**


訓練集準確率: 0.8074956672443674
測試集準確率: 0.7690175012996014

b. 交叉驗證結果:平均準確率約落在**0.80**左右

五折交叉驗證準確率: [0.80004333 0.80610919 0.80632582 0.80524263 0.80220971]
平均準確率: 0.8039861351819757


8. 最終決策樹: 下圖為最終決策樹的結果。

a. 完整圖



b. 細節解釋&說明


- 根據前述特徵重要性分析可知,「婚姻狀態」為影響income 最為關鍵的特徵,因此在決策樹模型建構過程中被選為根節點,作為模型進行高收入與低收入分類的起始依據。由根節點可看出,婚姻狀態對於收入是否高於 50K 具有高度的判別能力。




首先觀察決策樹的左子樹分支，該分支主要代表已婚族群。在此分支中，模型進一步以「資本利得」作為主要的分割條件，顯示資本收入在已婚族群中對於高收入判斷具有顯著影響。

當個體的資本利得偏低時，模型接續以「教育程度」進行細分。由此可發現，若教育程度較低，即使考量後續的年齡或工時等因素，其預測結果仍多半被歸類為低收入 ($\text{income} \leq 50K$)。


此外，在部分分支中可觀察到「年齡」與「每週工時」作為輔助分割條件，顯示在教育程度相近的情況下，年齡與工時仍會對收入產生次要影響。然而整體而言，左子樹的多數葉節點仍以低收入為主要預測結果。



- ii. 接著觀察右側子樹，該分支主要代表未婚族群。由決策樹的視覺化結果可發現，在此分支中，多數節點的最終預測結果皆為低收入 ($\text{income} \leq 50K$)，顯示「婚姻狀態」在模型判斷中對收入預測具有高度影響性。整體而言，未婚狀態在決策樹中較容易被歸類為低收入族群。



- iii. 結果說明: 根據決策樹預測模型的分析結果可知,「是否結婚」與收入之間存在明顯關聯, 婚姻狀態在模型中扮演關鍵的判斷角色。相較之下,「每週工時」雖然作為分割特徵之一, 但其對收入預測結果的影響程度相對較低, 顯示工時長短在本模型中並非主要的決定因素。




- iv. 程式碼附圖

```
# =====
# 1 3 決策樹圖
# =====
plt.figure(figsize=(25, 15))
plot_tree(model,
           feature_names=X_train_res.columns,
           class_names=["Low Income", "High Income"],
           filled=True,
           rounded=True,
           fontsize=10)

plt.show()
```

(三)羅吉斯回歸

1. 模型介紹:



羅吉斯回歸與線性回歸不同，線性回歸主要用於預測連續型數值，而羅吉斯回歸則常應用於處理分類問題，其目的在於將資料區分為不同類別。本研究中，羅吉斯回歸模型的目標是建立一個分類邊界，以區分高收入與低收入兩類族群。在建構模型之前，需先定義特徵(X)與標籤(Y)。我們以「收入」作為標籤，其中收入是否大於或等於 50K 作為分類依據；特徵則包含年齡、教育程度等相關變數。羅吉斯回歸模型以勝算比(Odds Ratio)作為基礎進行計算，勝算比為收入大於或等於 50K 的發生機率與收入小於 50K 的發生機率之比。透過對勝算比取對數後，再經由 Sigmoid 函數轉換，將預測結果限制在 0 至 1 之間，作為發生機率的表示。最終，

當預測機率大於或等於 0.5 時，判定為高收入(1)，反之則判定為低收入(0)。

2. 模型建立:

建構羅吉斯回歸的模型是使用Scikit-learn的LogisticRegression，訓練集和測試集分為70%和30%，迭代次數設為?代，優化器選擇lbfgs，再使用fit去擬合訓練集資料。下圖為程式碼。

```
# -----
# 1 建立羅吉斯回歸模型
log_model = LogisticRegression(max_iter=1000)

# -----
# 2 五折交叉驗證 (訓練集)
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
cv_scores = cross_val_score(log_model, X_train, y_train, cv=cv, scoring='accuracy')
print("訓練集 5-Fold CV Accuracy:", cv_scores)
print("訓練集平均 Accuracy:", cv_scores.mean())

# -----
# 3 訓練完整模型
log_model.fit(X_train, y_train)

# -----
# 4 訓練集預測
y_train_pred = log_model.predict(X_train)
y_train_prob = log_model.predict_proba(X_train)[:, 1]

# -----
# 5 測試集預測
y_test_pred = log_model.predict(X_test)
y_test_prob = log_model.predict_proba(X_test)[:, 1]

# -----
# 6 Accuracy
train_acc = accuracy_score(y_train, y_train_pred)
test_acc = accuracy_score(y_test, y_test_pred)
print(f"\n訓練集 Accuracy: {train_acc:.3f}")
print(f"\n測試集 Accuracy: {test_acc:.3f}")


# -----
# 7 分類報告
print("\n訓練集分類報告:\n", classification_report(y_train, y_train_pred))
print("\n測試集分類報告:\n", classification_report(y_test, y_test_pred))
```

由於發現測試集準確率高於訓練集、不符合常理，因此推斷可能有


以下原因:

- 模型的正則化效果/ 由於Scikit-learn預設應用L2正則化，防止過度擬合、提高泛化能力，使得模型在訓練集上的表現略差、測試集上表現更好。因此在模型建立時選擇將 `penalty='none'` 不使用正則化技術。
- 資料集分佈的差異/ 測試集和訓練集的數據分佈有所不同，也就是測試集中的數據特徵與訓練集相比可能更簡單或者噪音較少，表示特徵數據中可能包含過多離群值，導致測試集由於選取更少的資料因而較低的可能含有影響模型準確率的數值。

3. 混淆矩陣:



4. ROC曲線:



5. 交叉驗證:

訓練集 5-Fold CV Accuracy:

[0.77837955 0.77621317 0.77101386 0.7757799 0.777513

訓練集平均 Accuracy: 0.7757798960138648

6. 準確率:

訓練集 Accuracy: 0.776

測試集 Accuracy: 0.763

7. 特徵重要性:

特徵重要性與勝算比：

	feature	coefficient	odds_ratio
0	age_cat	1.190789	3.289675
8	edu_cat	0.970412	2.639031
2	sex_cat	-0.937305	0.391682
7	rel_cat	0.870867	2.388982
6	occ_cat	0.671576	1.957319
1	edun_cat	0.583137	1.791650
3	race_cat	-0.232318	0.792694
5	mar_cat	0.136833	1.146637
4	work_cat	0.013616	1.013709

陸、教授提問與問題回覆、解決策略

柒、附錄

(一)工作分配表(上台報告為共同項目)

111029208 吳文秀(組長)	資料前處理、隨機森林模型、簡報製作、協助部分書面報告
112029043 朱芯優	資料前處理、簡報製作、簡報製作與編排、書面報告
112029012 翁鈺淇	資料前處理、視覺化分析、隨機森林模型、協助部分書面報告
112029030 魏麒恩	資料前處理、視覺化分析、簡報製作、協助部分書面報告
112029040 劉涵雲	資料前處理、決策樹模型、羅吉斯回歸、簡報製作、協助部分書面報告

(二) 討論紀錄

這個時間大家可以嗎 18:55

12/13 (六)

淇
我可以歐 00:25

7n
可以 00:26

ai
我們有需要先行討論嗎 00:28

淇
我都可以欸 但是我星期日不太知道什麼時候回家 14:05

ai
這個時間大家可以嗎

已讀 4 15:38 可以

雲
那接下來要決定線上討論的時間 16:44

雲
我是 10/30 (三) 上午
10/31 (四) 上午 + 晚上有空 16:47


淇
禮拜三下午
禮拜四四點之後 16:47

雲
如果是下周報告的話 這個作業比較急 而且模型修正感覺會需要很多時間 17:10

ai
我三晚上 10.後 週四 4-5.30、9.後 週五 4-5.30、10.後 週六日皆可 17:11

@雲 禮拜四上完課妳有要先上班嗎

已讀 4 19:27



捌、心得感想

111029208 吳文秀: 這門課讓我學習到在進行資料探勘時，最重要的其實不是預測出來的結果，而是資料前處理的步驟，需要嚴謹地思考如何處理資料，定義標準要很明確，哪些該刪、哪些該留、要如何編碼分組都需要想得周到，我們組在編碼的部分遇到了許多難題，做模型時發現資料編碼編得太細而無法好好呈現數據，所以從頭來過重新編碼分組而浪費許多時間。在進行資料平衡時也同樣遇到困難，第一次做因為使用了錯誤的平衡方式而導致有非常多資料被浪費，後來聽取老師建議(上採樣)才得以讓資料更真實地顯示出來。所以我覺得前處理真

的是最重要的部分，一旦有問題後面的步驟就要全部重來，未來在進行資料探勘時，我學會更謹慎處理所擁有的資料。

112029012 翁鈺淇：修過這門課之後，更知道怎麼對一筆資料進行解析，解析的方法也不是只有一種，而是依照你想知道的角度。我覺得這門課很有趣，一開始修課的時候，我以為分析資料就是跟統計一模一樣的分析方法，慢慢了解之後才發現，其實兩門課程大有不同，相較於統計更佳深入地去理解，且多樣呈現資料的方式，也認識很多不一樣的名詞，例如：隨機森林、決策樹。上完之後我深刻發現大一、二知識基礎並沒有打好，謝謝老師有讓我重新鞏固知識的機會，也讓我更加知道資料探勘的重要性。

112029030 魏麒恩：這門課讓我了解資料解析是有多複雜，有很多道程序要做，可以透過很多種方式去探討，這部分會花很多時間但解出來的時候也會有一種成就感，每一種方式都需要花時間去理解，第一次做出來的時候很多東西都很陌生，很多名詞要查要背，深入了解後有比較知道該如何運用，統計有些地方沒有記好在做分析的時候就會很卡，要重新翻書，很多東西會類似，謝謝老師讓我更了解資料探勘在幹嘛以及如何應用。

112029040 劉涵雲：在資料探勘期末報告中，我們實際應用了決策樹與羅吉斯迴歸等方法進行分析，讓我第一次真正感受到模型與資料之間的互動關係。一開始我以為只要選擇合適的模型就能得到理想結果，但實際操作後才發現，模型的表現高度受到資料品質與變數選擇的影響。以決策樹為例，在實際建模與參數調整過程中，需要不斷測試與修正才能避免過度配適的問題。我深刻體會到資料探勘報告不只是跑出結果，而是要能有邏輯地說明分析過程與結論，這也讓我對資料分析與研究寫作有了更實際的認識。

112029043 朱芯優：

玖、參考資料

1.性別與種族對美國收入影響

- 性別

<https://www.gvm.com.tw/article/100314>

- 種族

<https://zh.wikipedia.org/zh-tw/%E7%BE%8E%E5%9B%BD%E7%A7%8D%E6%97%8F%E8%96%AA%E8%B5%84%E5%B7%AE%E8%B7%9D>

2.教育年數與工作收入

<https://www.gvm.com.tw/article/126554>

3.美國退休年齡

https://www.ccyp.com/CCYPContents?content_id=129848

4.美國工時標準

<https://www.dol.gov/sites/dolgov/files/WHD/legacy/files/whdfsChinese.pdf>