

成人人口普查收入

第三組

111029208	吳文秀
112029012	翁鈺淇
112029030	魏麒恩
112029040	劉涵雲
112029043	朱芯僊

目錄

01

研究背景

02

資料描述

03

資料前處理

04

問題假說

05

視覺化分析

06

實驗設計

07

參考文獻
& 分工表

08

Q&A 與建議

研究背景



研究背景

我們這次做的題目有關收入、教育、性別等等，這些關鍵字相連在一起會想到社會階層，成人人口普查可以幫助政策制定者，更了解社會資源的分配，進而制定更公平的社會制度。

資料描述



原始資料說明

- ① 該數據由 RONNY KOHAVI 和 BARRY BECKER(數據挖掘和可視化,SILICON GRAPHICS)從1994 年人口普查局數據庫中提取。
共有32,561筆資料，15個資料欄位。
- ② 其中包括類別型資料 9 欄
以及連續型資料 6欄。

一 類別型資料

欄位名稱	說明	範例值
workclass	工作類別 (如政府、私人企業、 自營等)	Private, Self-emp-not-inc, ?
education	教育程度名稱	HS-grad, Bachelors
marital.status	婚姻狀況	Married-civ-spouse, Divorced,Widowed, Separated,Never-married
occupation	職業類別	Prof-specialty, Sales

— 類別型資料

欄位名稱	說明	範例值
relationship	家庭關係	Husband, Not-in-family
race	種族	White, Black, Asian-Pac- Islander
sex	性別	Male, Female
native.country	原生國家	United-States, Mexico
income	收入分類 (是否超過 50,000 美元)	<=50K, >50K

— 連續型資料

欄位名稱	說明	範例值
age	年齡（以歲為單位）	17-90
fnlwgt	最終權重， 代表該筆樣本在母體中的代表性	12285-1,484,705
education.num	教育程度數值化 （年級數）	1-16
capital.gain	資本收益	0-99,999
capital.loss	資本損失	0-4,356
hours.per.week	每週工作時數	1-99

資料前處理



缺失值刪除

使用Excel將資料全部選取→點選資料點擊篩選問號
→成為新的資料→把新的資料拉進SPSS

刪除缺失值後
剩下**30162**筆資料

A	B	C	D	E	F	G	H
age	workclass	fnlwgt	educatio	educatio	marital	occupat	relati
63	?	29859	HS-grad	9	Married-ci?		Husb
76	?	224680	Prof-schoc	15	Married-ci?		Husb
67	?	184506	11th	7	Married-ci?		Husb
27	?	501172	Some-coll	10	Married-ci?		Husb
24	?	151153	Some-coll	10	Never-mai?		Not-i
61	?	139391	Some-coll	10	Married-ci?		Husb
69	?	323016	Bachelors	13	Married-ci?		Husb
58	?	266792	Some-coll	10	Married-ci?		Husb
17	?	304873	10th	6	Never-mai?		Own
20	?	273701	Some-coll	10	Never-mai?		Other
58	?	353244	Bachelors	13	Widowed?		Unm
75	?	111177	Bachelors	13	Widowed?		Not-i
65	?	224472	Prof-schoc	15	Never-mai?		Not-i
68	?	146645	Doctorate	16	Married-ci?		Husb
67	?	129188	Doctorate	16	Married-ci?		Husb
79	?	76641	Masters	14	Married-ci?		Husb
38	?	70282	Masters	14	Married-ci?		Wife
52	?	92968	Masters	14	Married-ci?		Wife

A	B	C	D
1	age	workclass	fnlwgt
19	61	Private	29059


1	age	workclass	fnlwgt	educatio	educatio	marital	occupat	relation	race	sex	capital.gai	capital.	hours.p	native.c	income
2	82	Private	132870	HS-grad	9	Widowed	Exec-man	Not-in-fan	White	Female	0	4356	18	United-Sta	<=50K
3	54	Private	140359	7th-8th	4	Divorced	Machine-c	Unmarrie	White	Female	0	3900	40	United-Sta	<=50K
4	41	Private	264663	Some-coll	10	Separated	Prof-speci	Own-child	White	Female	0	3900	40	United-Sta	<=50K
5	34	Private	216864	HS-grad	9	Divorced	Other-serv	Unmarrie	White	Female	0	3770	45	United-Sta	<=50K
6	38	Private	150601	10th	6	Separated	Adm-cleri	Unmarrie	White	Male	0	3770	40	United-Sta	<=50K
7	74	State-gov	88638	Doctorate	16	Never-mai	Prof-speci	Other-rela	White	Female	0	3683	20	United-Sta	>50K
8	68	Federal-gc	422013	HS-grad	9	Divorced	Prof-speci	Not-in-fan	White	Female	0	3683	40	United-Sta	<=50K
9	45	Private	172274	Doctorate	16	Divorced	Prof-speci	Unmarrie	Black	Female	0	3004	35	United-Sta	>50K
10	38	Self-emp-i	164526	Prof-schoc	15	Never-mai	Prof-speci	Not-in-fan	White	Male	0	2824	45	United-Sta	>50K
11	52	Private	129177	Bachelors	13	Widowed	Other-serv	Not-in-fan	White	Female	0	2824	20	United-Sta	>50K
12	32	Private	136204	Masters	14	Separated	Exec-man	Not-in-fan	White	Male	0	2824	55	United-Sta	>50K
13	46	Private	45363	Prof-schoc	15	Divorced	Prof-speci	Not-in-fan	White	Male	0	2824	40	United-Sta	>50K
14	45	Private	172822	11th	7	Divorced	Transport-	Not-in-fan	White	Male	0	2824	76	United-Sta	>50K
15	57	Private	317847	Masters	14	Divorced	Exec-man	Not-in-fan	White	Male	0	2824	50	United-Sta	>50K
16	34	Private	203034	Bachelors	13	Separated	Sales	Not-in-fan	White	Male	0	2824	50	United-Sta	>50K
17	37	Private	188774	Bachelors	13	Never-mai	Exec-man	Not-in-fan	White	Male	0	2824	40	United-Sta	>50K
18	29	Private	77009	11th	7	Separated	Sales	Not-in-fan	White	Female	0	2754	42	United-Sta	<=50K
19	61	Private	29059	HS-grad	9	Divorced	Sales	Unmarrie	White	Female	0	2754	25	United-Sta	<=50K
20	51	Private	153870	Some-coll	10	Married-ci	Transport-	Husband	White	Male	0	2603	40	United-Sta	<=50K
21	21	Private	34310	Assoc-voc	11	Married-ci	Craft-repa	Husband	White	Male	0	2603	40	United-Sta	<=50K
22	33	Private	228696	1st-4th	2	Married-ci	Craft-repa	Not-in-fan	White	Male	0	2603	32	Mexico	<=50K
23	49	Private	122066	5th-6th	3	Married-ci	Other-serv	Husband	White	Male	0	2603	40	Greece	<=50K
24	37	Self-emp-i	107164	10th	6	Never-mai	Transport-	Not-in-fan	White	Male	0	2559	50	United-Sta	>50K
25	38	Private	175360	10th	6	Never-mai	Prof-speci	Not-in-fan	White	Male	0	2559	90	United-Sta	>50K
26	23	Private	44064	Some-coll	10	Separated	Other-serv	Not-in-fan	White	Male	0	2559	40	United-Sta	>50K

缺失值檢查

確認資料內無缺失值

各欄位缺漏值統計：

	缺漏值數量
age	0
workclass	1836
fnlwgt	0
education	0
education.num	0
marital.status	0
occupation	1843
relationship	0
race	0
sex	0
capital.gain	0
capital.loss	0
hours.per.week	0
native.country	583
income	0



各欄位缺漏值統計：

	缺漏值數量
age	0
workclass	0
fnlwgt	0
education	0
education.num	0
marital.status	0
occupation	0
relationship	0
race	0
sex	0
capital.gain	0
capital.loss	0
hours.per.week	0
native.country	0
income	0
收入	0
教育程度	0
性別	0
種族	0


沒有發現缺漏值！

異常值刪除

age =>18 and age<=65
18歲以下未有工作能力
65歲以上已退休

capital_gain<=99999
為極端值
模型可能會被影響

刪除異常值後
剩下**28852**筆資料



資料編碼與分組

編碼

income : marital.status :

"0"表示"<=50k" "1"表示"離婚"

"1"表示">50k" "2"表示"已婚(配偶從軍)"

"3"表示"已婚(配偶為平民)"

sex : "4"表示"已婚(配偶長期在外)"

"1"表示"男" "5"表示"未婚"

"2"表示"女" "6"表示"分居"

"7"表示"喪偶"

分組

education.num :

0-5表示"教育程度低"

6-10表示"教育程度中"

11-15表示"教育程度中高"

16-20表示"教育程度高"


age :

18-25表示"青少年"

26-35表示"青壯年"

36-65表示"壯年"

資料平衡



SMOTE 平衡程式碼

```
# Step 1. 上傳資料
from google.colab import files
uploaded = files.upload()

import pandas as pd
import pyreadstat

file_name = list(uploaded.keys())[0]
df, meta = pyreadstat.read_sav(file_name)

# Step 2. y = income_bin (標籤)
y = df['income_bin']

# Step 3. 只選取「數值變項」來做 SMOTE
numeric_cols = df.select_dtypes(include=['int64',
'float64']).columns.tolist()
numeric_cols = [col for col in numeric_cols if col != 'income_bin'] #
防止收入重複進 x

X_numeric = df[numeric_cols]

# Step 4. 切訓練 / 測試集
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X_numeric, y, test_size=0.2, random_state=42, stratify=y)
```

SMOTE平衡程式碼

```
# Step 5. SMOTE (只能用在訓練集)
from imblearn.over_sampling import SMOTE
sm = SMOTE(random_state=42)
X_train_sm, y_train_sm = sm.fit_resample(X_train, y_train)

print("Before SMOTE:")
print(y_train.value_counts())
print("\nAfter SMOTE:")
print(y_train_sm.value_counts())

# Step 6. 合併成訓練集 (SMOTE 後)
train_smote = pd.concat([X_train_sm, y_train_sm.rename("income_bin")],
axis=1)
```


SMOTE平衡程式碼

```
# Step 7. 合併成測試集 (原始, 不做 SMOTE)
test_original = pd.concat([X_test, y_test.rename("income_bin")],
axis=1)


# Step 8. 輸出兩份 SAV
import pyreadstat

pyreadstat.write_sav(train_smote, "dataset1_train_smote.sav")
pyreadstat.write_sav(test_original, "dataset2_test_original.sav")

print("已成功輸出: dataset1_train_smote.sav (SMOTE 後訓練集) ")
print("已成功輸出: dataset2_test_original.sav (原始測試集) ")
```

視覺化分析






```
# Step 4. 抓出所有數值欄位
numeric_cols = df.select_dtypes(include=['float64', 'int64']).columns

print("可用於相關分析的欄位: ")
print(numeric_cols)


# Step 5. 計算相關矩陣
corr = df[numeric_cols].corr()
corr

# Step 6. 畫熱力圖
import seaborn as sns
import matplotlib.pyplot as plt


plt.figure(figsize=(12, 10))
sns.heatmap(corr, annot=True, cmap='coolwarm', fmt=".2f")
plt.title("Correlation Heatmap (Numerical Variable Improvement Analysis)")
plt.show()
```

教育程度和收入呈現正向關係，有教育程度越高收入越高的趨勢



- 婚姻溢價：已婚群體獲得高收入的比例顯著最高，確立了婚姻狀態與收入間的強烈正相關性。
- 離婚/喪偶者：過往婚姻中積累的年齡優勢與經濟資本仍持續發揮影響。



年齡和收入呈現正向
關係，顯示年齡越高
收入越高的趨勢

問題假說





探討哪些成人人口特徵
變化會對收入造成影響

實驗設計



切分資料集

[資料集3]

統計量

1=Training, 2=Testing

N	有效	14616
	遺漏	0

1=Training, 2=Testing

		次數分配表	百分比	有效百分比	累積百分比
有效	1.00	10247	70.1	70.1	70.1
	2.00	4369	29.9	29.9	100.0
	總計	14616	100.0	100.0	

一 預測模型


隨機森林

羅吉斯回歸

交叉驗證方式 → 五折驗證

隨機森林

• 模型介紹




1. Bootstarp是指重新抽取原本的資料在產生新的資料，這過程保證是隨機且均勻可重複的


2. 隨機森林是把很多科決策樹組在一起，但每棵樹都有自己的資料和特徵，讓結果比較準確

羅吉斯回歸

特徵(X)
標籤(Y)



勝算比取對數




Sigmoid函數

$$S(X) = \frac{1}{1 + e^{-X}}$$

≥ 0.5 為 1
 < 0.5 為 0

$$\text{logit}(\text{Odds}) = \ln\left(\frac{p}{1-p}\right) = w_0 + w_1 X$$

會議記錄



一

參考文獻 & 分工表



參考文獻

1.性別與種族對美國收入影響

Greenman&Xie (2008) - Double Jeopardy?

The Interaction of Gender and Race on Earnings in the U.S.

2.教育年數與工作收入

Polachek(2007) - The Mincer Earnings Function and Its Applications.

Heckman(2005) - The Mincer Equation and Beyond.

3.美國退休年齡

https://www.ccyp.com/CCYPContents?content_id=129848

4.美國工時標準

<https://www.dol.gov/sites/dolgov/files/WHD/legacy/files/whdfsChinese.pdf>

分工表

111029208 吳文秀	112029012 翁鈺淇	112029030 魏麒恩	112029040 劉涵雲	112029043 朱芯僊
視覺化分析 模型製作 簡報製作 上台報告 Q&A	資料前處理 視覺化分析 模型製作 簡報製作 上台報告	資料前處理 視覺化分析 簡報製作 上台報告 Q&A	資料前處理 視覺化分析 模型製作 簡報製作 上台報告 Q&A	資料介紹 資料前處理 簡報製作 簡報編排

Q&A 與建議



Q1：為什麼年齡區段選擇18~74歲，是否合適？


A1：我們做箱型圖時顯示出來最小離群值歲數是74，未考慮到在美國65歲以上可能已退休，無勞動能力及工作收入，經修改後已將65歲以上人口設為異常值並刪除。

Q2：Bootstrap的分析，針對無母體採樣是否合適？

A2：它通過從原始樣本中重複有放回地抽樣來估計統計量的變異性，適合母體分佈未知的情況。

Q3：為什麼不使用熱力圖？

A3：我們原本使用卡方檢定，卻忽略進行卡方檢定前的要求，而後改用熱力圖，即可呈現所有卡方檢定圖表中各變項與收入之間的關聯性，右方為新增後的熱力圖。



Q4：為什麼使用下採樣？

A4：因為當初低收入資料相較高收入多，所以使用下採樣，卻刪除太多筆導致資料被浪費。已聽取老師建議，先切分資料集，並將其中80%進行資料平衡，低收入仍採用下採樣的方式，高收入的部分則改用Smote平衡(上採樣)，這樣的平衡方式對於模型的訓練，資料量會相對完整。

建議一：研究目的需重新思考，目前探討的問題只有統計的部分，應聚焦於當其他變項如何變化時，收入會是0或1，並可進一步計算其相對風險。

建議二：單看變項的平均值只能看出趨勢，無法得出該變項會影響收入的結論，建議納入其他變項一起考量。

.....

Thank
you

.....