

成人人口普查收入

第三組

111029208	吳文秀
112029012	翁鈺淇
112029030	魏麒恩
112029040	劉涵雲
112029043	朱芯僊

目錄

01

資料描述
& 前處理

02

問題假說

03

視覺化分析

04

實驗設計

05

參考文獻

06

分工表

資料描述 & 前處理



原始資料說明

- 1 該數據由 RONNY KOHAVI 和 BARRY BECKER(數據挖掘和可視化,SILICON GRAPHICS)從1994 年人口普查局數據庫中提取。
共有32,561筆資料，15個資料欄位。
- 2 其中包括類別型資料 9 欄
以及連續型資料 6欄。

類別型資料



No.	欄位名稱	說明	範例值
B	workclass	工作類別（如政府、私人企業、自營等）	Private, Self-emp-not-inc, ?
D	education	教育程度名稱	HS-grad, Bachelors
F	marital.status	婚姻狀況	Married-civ-spouse, Divorced,Widowed, Separated,Never-married
G	occupation	職業類別	Prof-specialty, Sales


No.	欄位名稱	說明	範例值
H	relationship	家庭關係	Husband, Not-in-family
I	race	種族	White, Black, Asian- Pac-Islander
J	sex	性別	Male, Female
N	native.country	原生國家	United-States, Mexico
O	income	收入分類 (是否超過 50,000 美元)	<=50K, >50K

連續型資料



No.	欄位名稱	說明	範例值
A	age	年齡（以歲為單位）	17-90
C	fnlwgt	最終權重，代表該筆樣本在母體中的代表性	12285-1,484,705
E	education.num	教育程度數值化（年級數）	1-16
K	capital.gain	資本收益	0-99,999
L	capital.loss	資本損失	0-4,356
M	hours.per.week	每週工作時數	1-99

描述性統計



具有離群值

使用Google Colab 生成

缺失值刪除

使用Excel將資料全部選取→點選資料點擊篩選問號
→成為新的資料→把新的資料拉進SPSS

刪除缺失值後
剩下**30162**筆資料

A	B	C	D	E	F	G	H
age	workclass	fnlwgt	educatio	educatio	marital	occupat	relati
?	?	?	HS-grad	9	Married-ci?	Husb	
76?	22	13870	Prof-schoc	15	Married-ci?	Husb	
67?	1845	13870	10th	7	Married-ci?	Husb	
27?	50117	13870	Some-coll	10	Married-ci?	Husb	
24?	151153	13870	Some-coll	10	Never-mar?	Not-i	
61?	139391	13870	Some-coll	10	Married-ci?	Husb	
69?	323016	13870	Bachelors	13	Married-ci?	Husb	
58?	266792	13870	Some-coll	10	Married-ci?	Husb	
17?	304873	13870	10th	6	Never-mar?	Own	
20?	273701	13870	Some-coll	10	Never-mar?	Other	
58?	353244	13870	Bachelors	13	Widowed?	Unm	
75?	111177	13870	Bachelors	13	Widowed?	Not-i	
65?	224472	13870	Prof-schoc	15	Never-mar?	Not-i	
58?	146645	13870	Doctorate	16	Married-ci?	Husb	
?	129177	13870	Doctorate	16	Married-ci?	Husb	
79?	70282	13870	Masters	14	Married-ci?	Husb	
38?	70282	13870	Masters	14	Married-ci?	Wife	
52?	92968	13870	Masters	14	Married-ci?	Wife	

A	B	C	D
1	age	workcla	fnlwgt
2	age	workcla	fnlwgt
3	age	workcla	fnlwgt
4	age	workcla	fnlwgt
5	age	workcla	fnlwgt
6	age	workcla	fnlwgt
7	age	workcla	fnlwgt
8	age	workcla	fnlwgt
9	age	workcla	fnlwgt
10	age	workcla	fnlwgt
11	age	workcla	fnlwgt
12	age	workcla	fnlwgt
13	age	workcla	fnlwgt
14	age	workcla	fnlwgt
15	age	workcla	fnlwgt
16	age	workcla	fnlwgt
17	age	workcla	fnlwgt
18	age	workcla	fnlwgt
19	age	workcla	fnlwgt
20	age	workcla	fnlwgt
21	age	workcla	fnlwgt
22	age	workcla	fnlwgt
23	age	workcla	fnlwgt
24	age	workcla	fnlwgt
25	age	workcla	fnlwgt
26	age	workcla	fnlwgt

1	age	workclass	fnlwgt	educatio	educatio	marital	occupat	relation	race	sex	capital.gai	capital.	hours.p	native.c	income
2	82	Private	132870	HS-grad	9	Widowed	Exec-man	Not-in-fan	White	Female	0	4356	18	United-Sta	<=50K
3	54	Private	140359	7th-8th	4	Divorced	Machine-c	Unmarrie	White	Female	0	3900	40	United-Sta	<=50K
4	41	Private	264663	Some-coll	10	Separated	Prof-speci	Own-child	White	Female	0	3900	40	United-Sta	<=50K
5	34	Private	216864	HS-grad	9	Divorced	Other-serv	Unmarrie	White	Female	0	3770	45	United-Sta	<=50K
6	38	Private	150601	10th	6	Separated	Adm-cleri	Unmarrie	White	Male	0	3770	40	United-Sta	<=50K
7	74	State-gov	88638	Doctorate	16	Never-mar	Prof-speci	Other-rela	White	Female	0	3683	20	United-Sta	>50K
8	68	Federal-gc	422013	HS-grad	9	Divorced	Prof-speci	Not-in-fan	White	Female	0	3683	40	United-Sta	<=50K
9	45	Private	172274	Doctorate	16	Divorced	Prof-speci	Unmarrie	Black	Female	0	3004	35	United-Sta	>50K
10	38	Self-emp-i	164526	Prof-schoc	15	Never-mar	Prof-speci	Not-in-fan	White	Male	0	2824	45	United-Sta	>50K
11	52	Private	129177	Bachelors	13	Widowed	Other-serv	Not-in-fan	White	Female	0	2824	20	United-Sta	>50K
12	32	Private	136204	Masters	14	Separated	Exec-man	Not-in-fan	White	Male	0	2824	55	United-Sta	>50K
13	46	Private	45363	Prof-schoc	15	Divorced	Prof-speci	Not-in-fan	White	Male	0	2824	40	United-Sta	>50K
14	45	Private	172822	11th	7	Divorced	Transport-	Not-in-fan	White	Male	0	2824	76	United-Sta	>50K
15	57	Private	317847	Masters	14	Divorced	Exec-man	Not-in-fan	White	Male	0	2824	50	United-Sta	>50K
16	34	Private	203034	Bachelors	13	Separated	Sales	Not-in-fan	White	Male	0	2824	50	United-Sta	>50K
17	37	Private	188774	Bachelors	13	Never-mar	Exec-man	Not-in-fan	White	Male	0	2824	40	United-Sta	>50K
18	29	Private	77009	11th	7	Separated	Sales	Not-in-fan	White	Female	0	2754	42	United-Sta	<=50K
19	61	Private	29059	HS-grad	9	Divorced	Sales	Unmarrie	White	Female	0	2754	25	United-Sta	<=50K
20	51	Private	153870	Some-coll	10	Married-ci	Transport-	Husband	White	Male	0	2603	40	United-Sta	<=50K
21	21	Private	34310	Assoc-voc	11	Married-ci	Craft-repa	Husband	White	Male	0	2603	40	United-Sta	<=50K
22	33	Private	228696	1st-4th	2	Married-ci	Craft-repa	Not-in-fan	White	Male	0	2603	32	Mexico	<=50K
23	49	Private	122066	5th-6th	3	Married-ci	Other-serv	Husband	White	Male	0	2603	40	Greece	<=50K
24	37	Self-emp-i	107164	10th	6	Never-mar	Transport-	Not-in-fan	White	Male	0	2559	50	United-Sta	>50K
25	38	Private	175360	10th	6	Never-mar	Prof-speci	Not-in-fan	White	Male	0	2559	90	United-Sta	>50K
26	23	Private	44064	Some-coll	10	Separated	Other-serv	Not-in-fan	White	Male	0	2559	40	United-Sta	>50K

缺失值檢查

確認資料內無缺失值

各欄位缺漏值統計：

	缺漏值數量
age	0
workclass	1836
fnlwgt	0
education	0
education.num	0
marital.status	0
occupation	1843
relationship	0
race	0
sex	0
capital.gain	0
capital.loss	0
hours.per.week	0
native.country	583
income	0

各欄位缺漏值統計：

	缺漏值數量
age	0
workclass	0
fnlwgt	0
education	0
education.num	0
marital.status	0
occupation	0
relationship	0
race	0
sex	0
capital.gain	0
capital.loss	0
hours.per.week	0
native.country	0
income	0
收入	0
教育程度	0
性別	0
種族	0

沒有發現缺漏值！

使用Google Colab 生成

異常值檢查 與刪除

異常值筆數統計：
年齡異常 (≤ 17 或 ≥ 74) : 569
資本收益異常 (≥ 99999) : 148
總異常筆數 (有任一條件符合者) : 715

以下為符合異常條件的資料列：

	age	workclass	fnlgt	education	education.num	marital.status	occupation	relationship	race	sex	capital.gain	capital.loss	hours.per.week	native.country	income
0	82	Private	132870	HS-grad	9	Widowed	Exec-managerial	Not-in-family	White	Female				United-States	$\leq 50K$
5	74	State-gov	88638	Doctorate	16	Never-married	Prof-specialty	Other-relative	White	Female				United-States	$> 50K$
102	78	Self-emp-inc	188044	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male				United-States	$> 50K$
104	83	Self-emp-inc	153183	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male				United-States	$> 50K$
114	81	Private	177408	HS-grad	9	Married-civ-spouse	Exec-managerial	Husband	White	Male				United-States	$> 50K$
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
29928	90	Private	313749	HS-grad	9	Widowed	Adm-clerical	Unmarried	White	Female	0	0	25	United-States	$\leq 50K$
29933	17	Private	311907	11th	7	Never-married	Other-service	Own-child	White	Male	0	0	25	United-States	$\leq 50K$
29981	75	Self-emp-not-inc	192813	Masters	14	Widowed	Sales	Not-in-family	White	Male	0	0	45	United-States	$\leq 50K$
30071	17	Private	117798	10th	6	Never-married	Other-service	Own-child	White	Male	0	0	20	United-States	$\leq 50K$
30081	85	Private	98611	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	3	Poland	$\leq 50K$

刪除缺失值後
剩下29447筆資料

資料編碼

income :

"0"表示" $\leq 50k$ "

"1"表示" $> 50k$ "

education.num :

0-5表示"教育程度低"

6-10表示"教育程度中"

11-15表示"教育程度中高"

16-20表示"教育程度高"

sex :

"1"表示"男"

"2"表示"女"

race :

"1"表示"白人"

"2"表示"黑人"

"3"表示"亞洲裔美國人"

"4"表示"愛斯基摩人"

"5"表示"其他"

原資料樣本不平衡

收入

		次數分配表	百分比	有效百分比	累積百分比
有效	<=50K	22132	75.2	75.2	75.2
	>50K	7315	24.8	24.8	100.0
	總計	29447	100.0	100.0	

平衡樣本-程式碼

random=24.8/75.2


```
1  *=== 檢查各收入群筆數 ===.  
2  FREQUENCIES VARIABLES=income.  
3  
4  *=== 產生隨機數 ===.  
5  COMPUTE random = RV.UNIFORM(0,1).  
6  ►  
7  *=== 下採樣：僅保留高收入者 + 部分低收入者 ===.  
8  SELECT IF (income = ">50K") OR (income = "<=50K" AND random <= 0.329787234).  
9  EXECUTE.  
10  
11 *=== 檢查抽樣後分布 ===.  
12 FREQUENCIES VARIABLES=income.  
13
```


平衡樣本-結果

資料平衡後的高低收入數量
各佔百分之50

income					
		次數分配表	百分比	有效百分比	累積百分比
有效	<=50K	7301	50.0	50.0	50.0
	>50K	7315	50.0	50.0	100.0
	總計	14616	100.0	100.0	

問題假說





探討成人人口特徵 對整體收入的影響

研究問題假設

1. 教育程度對收入的影響
2. 性別對收入的影響
3. 種族對收入的影響
4. 三個變項對收入的影響程度

1. 教育程度對收入的影響

預期結果

教育程度與收入呈正相關

教育程度高 → 收入高

教育程度低 → 收入低

2. 性別對收入的影響

預期結果

男性的收入較女性高

因為女性可能扮演孕婦及家庭主婦
等社會角色

3. 種族對收入的影響

預期結果

白人收入普遍較其他四者高
因為美國的勞動市場對白人較友善

4. 三個變項對收入的影響程度


預期結果

教育程度對於收入的影響最高
因為提升個人技能與知識水準
能增加就業機會與高薪職位的可能性

視覺化分析




教育程度對收入的影響



教育程度越高收入也越高
表示教育程度和收入之間
存在正相關關係


性別對收入的影響

圖表



男性的平均收入
比女性的平均收入高

一 種族對收入的影響



種族的平均收入由高到低為：
亞裔美國人 > 白人 > 黑人
> 愛斯基摩人 > 其他群體

卡方檢定檢測顯著性

教育程度v.s收入


性別v.s收入

種族v.s收入

	值	df	漸近顯著性 (兩端)
Pearson 卡方檢定	1731.794 ^a	3	<.001
概似比	1808.626	3	<.001
線性對線性關聯	1713.220	1	<.001
有效觀察值的數目	14616		

a. 0 單元 (0.0%) 預期計數小於 5。預期的計數下限為 146.86。

顯著性 <0.05




顯示教育程度與收入具有顯著關聯

	值	df	漸近顯著性 (兩端)
Pearson 卡方檢定	1066.931 ^a	1	<.001
連續校正 ^b	1065.712	1	<.001
概似比	1096.209	1	<.001
費雪 (Fisher) 精確檢定			
線性對線性關聯	1066.858	1	<.001
有效觀察值的數目	14616		

a. 0 單元 (0.0%) 預期計數小於 5。預期的計數下限為 1959.12。

顯著性 <0.05




顯示性別與收入具有顯著關聯

	值	df	漸近顯著性 (兩端)
Pearson 卡方檢定	241.301 ^a	4	<.001
概似比	248.428	4	<.001
線性對線性關聯	110.666	1	<.001
有效觀察值的數目	14616		

a. 0 單元 (0.0%) 預期計數小於 5。預期的計數下限為 46.46。

顯著性 <0.05



顯示種族與收入具有顯著關聯

教育程度v.s收入

對稱的測量

		值	漸近標準誤 ^a	大約 T ^b	大約顯著性
名義變數對名義變數	Phi	.344			<.001
	Cramer's V	.344			<.001
等距對等距	Pearson's R	.342	.007	44.052	<.001 ^c
次序對次序	Spearman 相關性	.344	.008	44.229	<.001 ^c
有效觀察值的數目		14616			

a. 未使用虛無假設。

b. 正在使用具有虛無假設的漸近標準誤。

c. 基於常態逼近。

教育程度與收入
呈正向中度相關

皮爾森積差相關係數

關係的程度	正向關係	負向關係
低度相關	0.1 至 0.3	-0.1 至 -0.3
中度相關	0.3 至 0.5	-0.3 至 -0.5
高度相關	0.5 至 1.0	-0.5 至 -1.0

性別v.s收入

對稱的測量

		值	漸近標準誤 ^a	大約 T ^b	大約顯著性
名義變數對名義變數	Phi	-.270			<.001
	Cramer's V	.270			<.001
等距對等距	Pearson's R	-.270	.008	-33.923	<.001 ^c
次序對次序	Spearman 相關性	-.270	.008	-33.923	<.001 ^c
有效觀察值的數目		14616			

a. 未使用虛無假設。

b. 正在使用具有虛無假設的漸近標準誤。

c. 基於常態逼近。

皮爾森積差相關係數

關係的程度	正向關係	負向關係
低度相關	0.1 至 0.3	-0.1 至 -0.3
中度相關	0.3 至 0.5	-0.3 至 -0.5
高度相關	0.5 至 1.0	-0.5 至 -1.0

性別與收入
呈負向低度相關

種族 v.s 收入

對稱的測量

		值	漸近標準誤 ^a	大約 T ^b	大約顯著性
名義變數對名義變數	Phi	.128			<.001
	Cramer's V	.128			<.001
等距對等距	Pearson's R	-.087	.008	-10.559	<.001 ^c
次序對次序	Spearman 相關性	-.102	.008	-12.425	<.001 ^c
有效觀察值的數目		14616			

a. 未使用虛無假設。

b. 正在使用具有虛無假設的漸近標準誤。

c. 基於常態逼近。

皮爾森積差相關係數

關係的程度	正向關係	負向關係
低度相關	0.1 至 0.3	-0.1 至 -0.3
中度相關	0.3 至 0.5	-0.3 至 -0.5
高度相關	0.5 至 1.0	-0.5 至 -1.0

種族與收入
呈正向低度相關

三個變項對收入的影響程度

教育程度v.s收入	正向中度相關
性別v.s收入	負向低度相關
種族v.s收入	正向低度相關

教育程度對收入的
影響程度最高

實驗設計




一 預測模型

隨機森林

羅吉斯回歸

隨機森林

• 模型介紹



1. Bootstarp是指重新抽取原本的資料在產生新的資料，這過程保證是隨機且均勻可重複的


2. 隨機森林是把很多科決策樹組在一起，但每棵樹都有自己的資料和特徵，讓結果比較準確

羅吉斯回歸


$$S(X) = \frac{1}{1 + e^{-X}}$$

≥ 0.5 為 1
 < 0.5 為 0

特徵(X)
標籤(Y)




勝算比取對數



Sigmoid函數

$$\text{logit}(\text{Odds}) = \ln\left(\frac{p}{1-p}\right) = w_0 + w_1 X$$

會議記錄



參考文獻 & 分工表



參考文獻



分工表

111029208 吳文秀	112029012 翁鈺淇	112029030 魏麒恩	112029040 劉涵雲	112029043 朱芯僊
視覺化分析 隨機森林 模型製作 簡報製作 上台報告	視覺化分析 隨機森林 模型製作 簡報製作 上台報告	隨機森林 模型製作 簡報製作 上台報告	spss資料前 處理 視覺化分析 羅吉斯回歸 模型製作 簡報製作 上台報告	資料介紹 視覺化資料 前處理 簡報製作 簡報編排

.....

Thank
you

.....